

DESCRIPCIÓN PIPELINE DE MLOPS – PREDICCIÓN SÍNTOMAS DE PACIENTES

El objetivo principal de este sistema es desarrollar una solución basada en aprendizaje automático (ML) que permita predecir el tipo de enfermedad que podría estar afectando a un paciente, a partir de una entrada de síntomas. Este sistema busca asistir y colaborar a profesionales de la salud en el diagnóstico preliminar y la priorización de atención médica, particularmente en contextos donde se requiere una respuesta rápida o en regiones con recursos limitados.

Cada etapa del pipeline está diseñada para abordar desafíos específicos en el procesamiento de datos médicos, especialmente críticos cuando se combinan aquellas enfermedades comunes (datos abundantes) con enfermedades huérfanas (datos escasos).

1. INGESTA Y GESTIÓN DE DATOS

La base del sistema parte de la recolección de datos estructurados, los cuales contienen registros sintomáticos de pacientes (por ejemplo, reportes de síntomas, observaciones clínicas o resultados de primeras evaluaciones médicas). Estos datos pueden provenir de múltiples fuentes, como formularios digitales, historiales electrónicos, registros hospitalarios, estudios académicos. Existe un desafío grande en la recolección de los datos dado al desbalance de las clases ya que hay más muestras de enfermedades comunes que de enfermedades huérfanas lo que mas adelante puede dificultar el entrenamiento sin sobreajuste.

Durante la ingesta, se aplican controles automáticos de validación: detección de entradas erróneas, manejo de valores faltantes, verificación de formatos, y control de duplicados. Toda esta etapa está automatizada para permitir la incorporación continua de nueva información.

2. PREPROCESAMIENTO Y AUMENTO DE DATOS

Una vez validados los datos, ingresan a una etapa de limpieza, imputación, detección de outliers, escalado, transformación, donde se preparan para su uso en modelos de aprendizaje automático. Esta etapa incluye:

- **Codificación de variables categóricas** (por ejemplo, síntomas en texto a variables codificadas).

- **Estandarización y normalización de valores clínicos numéricos** (como edad o duración de síntomas).
- **Imputación inteligente de valores faltantes** mediante técnicas estadísticas o modelos predictivos.
- **Generación de características derivadas**, como combinaciones sintomáticas o patrones temporales.
- **Reducción de dimensionalidad**, si es necesario, para evitar ruido en el aprendizaje. Igualmente, se aplican técnicas de aumento de datos debido a la poca cantidad de datos de enfermedad huérfana. Se utilizan métodos de generación de datos sintéticos con SMOTE y GANS.

3. ENTRENAMIENTO DEL MODELO DE PREDICCIÓN

El modelo predictivo principal es un clasificador supervisado, capaz de aprender patrones complejos entre la presencia de síntomas y la probabilidad de que el paciente esté sano o padezca una enfermedad, común o rara.

Para su entrenamiento, se prueba con distintos algoritmos (árboles de decisión, redes neuronales profundas), y se selecciona el mejor en función del rendimiento sobre los datos de validación.

4. VALIDACIÓN, EVALUACIÓN Y AUDITORIA

Antes del despliegue, el modelo se somete a pruebas rigurosas. Se emplean técnicas de validación cruzada y conjuntos de test representativos para evaluar su rendimiento. Las métricas clave incluyen:

- **Precisión (accuracy)**: Para evaluar la tasa global de aciertos.
- **Recall y sensibilidad**: Críticas en contextos clínicos para reducir falsos negativos.
- **AUC-ROC**: Para medir la capacidad discriminativa del modelo.
- **Matriz de confusión detallada**, estratificada por tipos de enfermedad.

Además, se generan reportes de auditoría interpretables para garantizar que las predicciones no solo sean precisas, sino también comprensibles para los médicos. Se aplican técnicas de explicabilidad para mostrar la contribución de cada síntoma a la predicción final.

5. DESPLIEGUE DEL MODELO EN PRODUCCIÓN

Una vez validado, el modelo se empaqueta como un microservicio mediante Docker y se despliega en un entorno de producción (como Streamlit Cloud, AWS o una plataforma on-premise hospitalaria). El servicio ofrece una API REST segura, capaz de recibir nuevos datos de pacientes y entregar una predicción casi en tiempo real.

6. MONITOREO Y FEEDBACK

El ciclo de vida no termina con el despliegue. El sistema se mantiene en observación constante mediante herramientas de monitoreo de rendimiento y datos en tiempo real. Algunas prácticas clave incluyen:

- Detección de data drift y concept drift: Cambios en la distribución de síntomas o en la relación entre síntomas y enfermedades
- Alarmas automáticas si el rendimiento baja bajo umbrales predefinidos.
- Retroalimentación, cuando los médicos marcan predicciones incorrectas y se debe realizar un reentrenamiento con nuevos datos.

Como conclusión, este pipeline aborda de manera integral los retos de predicción en el dominio médico, considerando tanto la escasez de datos en enfermedades huérfanas como la necesidad de sistemas robustos y auditables. La combinación de modelos adaptados, control de calidad y monitoreo constante lo hace apto para aplicaciones en el entorno hospitalario o de salud pública.